

Partie 4 - Restitution Finale

Notebook redigé en vue d'un export PDF. L'objectif est de fournir une restitution complète, argumentée et exploitable pour la prise de décision RH.

```
In [7]: from pathlib import Path
import importlib
import sys
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

PROJECT_ROOT = Path.cwd().resolve()
if not (PROJECT_ROOT / "raw").exists():
    PROJECT_ROOT = PROJECT_ROOT.parent

if str(PROJECT_ROOT) not in sys.path:
    sys.path.append(str(PROJECT_ROOT))

import hr_analysis_utils as utils
importlib.reload(utils)

MahalanobisAnomalyDetector = utils.MahalanobisAnomalyDetector
random_oversample_minority = utils.random_oversample_minority
SimpleLogisticRegression = utils.SimpleLogisticRegression
attrition_by_group = utils.attrition_by_group
attrition_gap_summary = utils.attrition_gap_summary
coefficient_importance = utils.coefficient_importance
correlation_with_attrition = utils.correlation_with_attrition
dataset_overview = utils.dataset_overview
kpi_table = utils.kpi_table
load_data = utils.load_data
missing_summary = utils.missing_summary
numeric_summary = utils.numeric_summary
plot_bar = utils.plot_bar
plot_box_by_attrition = utils.plot_box_by_attrition
plot_correlation_heatmap = utils.plot_correlation_heatmap
plot_histogram = utils.plot_histogram
plot_top_coefficients = utils.plot_top_coefficients
prepare_model_data = utils.prepare_model_data
prepare_numeric_anomaly_data = utils.prepare_numeric_anomaly_data
pr_auc_score_manual = utils.pr_auc_score_manual
roc_auc_score_manual = utils.roc_auc_score_manual
salary_gap_by_gender = utils.salary_gap_by_gender
average_by_group = utils.average_by_group
top_attrition_segments = utils.top_attrition_segments
find_best_threshold = utils.find_best_threshold
classification_metrics = utils.classification_metrics

DATA_PATH = PROJECT_ROOT / "raw" / "people_analytics_dataset.csv"
df = load_data(DATA_PATH)
pd.set_option("display.max_columns", 100)
```

Contexte

La DRH souhaite mieux comprendre les dynamiques de depart, d'engagement, d'evolution de carriere, de remuneration et de mobilite interne au sein d'une entreprise internationale d'environ 8 000 collaborateurs.

Le dataset analyse contient **8 020 collaborateurs** et **28 variables**. L'objectif etait double :

1. transformer les donnees RH en indicateurs de pilotage
2. construire un premier modele de prediction de l'attrition

Faits marquants de l'EDA et de l'analyse RH

1. Une attrition globalement faible mais non homogene

- Le taux d'attrition global s'etablit a **2,59 %**.
- Les niveaux les plus eleves apparaissent en **France (3,81 %)** et dans le **departement IT (2,89 %)**.
- Le niveau de teletravail **75 %** ressort egalement comme une modalite plus exposee dans ce dataset.

2. L'engagement et la securite psychologique jouent un role de fond

- Les collaborateurs partis ont un **engagement plus faible** que les collaborateurs restes.
- Leur **securite psychologique** est egalement plus basse.
- Les populations avec engagement faible affichent un taux d'attrition superieur aux autres groupes.

3. Les conditions de travail donnent des signaux complementaires

- Les collaborateurs partis presentent un peu plus d'**absenteisme** et d'**heures supplementaires**.
- Ils ont aussi recu **moins de formation** en moyenne.

4. Carriere, mobilite et remuneration


- Environ **24,64 %** des collaborateurs ont eu une promotion sur 3 ans.
- La **mobilit  interne** concerne **63,72 %** des collaborateurs au moins une fois.
- Le **salaire moyen** est de **62 313** par an, avec une progression nette selon le niveau hierarchique.
- Un ecart brut apparait entre salaire moyen des femmes et des hommes, ce qui justifie une analyse plus fine par poste, pays et niveau.


```
In [8]: kpi_table(df)
```

Out[8]:

	KPI	Valeur
0	Effectif total	8020.00
1	Taux d'attrition (%)	2.59
2	Score d'engagement moyen	68.15
3	Score de securite psychologique moyen	66.19
4	Taux de promotion sur 3 ans (%)	24.64
5	Taux de mobilite interne (%)	63.72
6	Heures de formation moyennes	34.64
7	Absenteisme moyen (jours)	6.93
8	Heures supp. moyennes	19.55
9	Salaire moyen annuel	62313.28
10	Bonus annuel moyen	4997.64

```
In [9]: plot_bar(attrition_by_group(df, "department"), "department", "attrition_rate_pct")
plot_bar(attrition_by_group(df, "country"), "country", "attrition_rate_pct", tit
```





Resultats du modele predictif

Le modele retenu est une regression logistique interpretable. Il a ete entraine sur des donnees nettoyees et encodees, avec ponderation des classes pour compenser la rarete des departs.

```
In [10]: prepared = prepare_model_data(df, drop_columns=["employee_id"])
model = SimpleLogisticRegression(learning_rate=0.05, epochs=4000, reg_strength=0.01)
model.fit(prepared.X_train, prepared.y_train)
best_threshold = find_best_threshold(prepared.y_val, model.predict_proba(prepared.X_val))
test_scores = model.predict_proba(prepared.X_test)
test_metrics = classification_metrics(prepared.y_test, test_scores, threshold=best_threshold)

pd.DataFrame(
    [
        ("ROC-AUC", roc_auc_score_manual(prepared.y_test, test_scores)),
        ("PR-AUC", pr_auc_score_manual(prepared.y_test, test_scores)),
        ("Recall", test_metrics["recall"]),
        ("Precision", test_metrics["precision"]),
        ("F1-score", test_metrics["f1_score"]),
    ],
    columns=["Metrique", "Valeur"],
).round(4)
```

Out[10]:

	Metrique	Valeur
0	ROC-AUC	0.5951
1	PR-AUC	0.0358
2	Recall	0.0476
3	Precision	0.0244
4	F1-score	0.0323

```
In [11]: coefficient_importance(model, prepared.feature_names, top_n=15)
```

Out[11]:

	feature	coefficient	abs_coefficient	odds_ratio
52	job_role_ML Engineer	-0.7508	0.7508	0.4720
2	contracted_hours_weekly	-0.3628	0.3628	0.6957
8	training_hours	-0.3038	0.3038	0.7380
16	salary	-0.2979	0.2979	0.7424
12	overtime_hours	0.2585	0.2585	1.2950
11	absenteeism_days	0.2563	0.2563	1.2922
15	psychological_safety_score	-0.2535	0.2535	0.7761
49	job_role_Frontend Developer	0.2440	0.2440	1.2764
84	overtime_band_26+	-0.2314	0.2314	0.7934
44	job_role_Data Analyst	0.2234	0.2234	1.2503
90	salary_quartile_Q2	-0.2004	0.2004	0.8184
81	overtime_band_0-5	0.1991	0.1991	1.2204
80	engagement_band_Very High	-0.1859	0.1859	0.8304
91	salary_quartile_Q3	0.1768	0.1768	1.1934
7	engagement_score	0.1730	0.1730	1.1889

Interpretation

- Les performances du modele restent **modestes**. Il identifie un signal, mais insuffisant pour une decision individuelle fiable.
- Les variables les plus contributives vont dans le sens des analyses descriptives : **formation, securite psychologique, salaire** et **absenteisme** participent au signal.
- Ce resultat est coherent avec un contexte RH ou les departes sont rares et probablement influences par des facteurs non captures dans le dataset.

Experience complementaire : detection d'anomalie

Une approche alternative a ete testee pour tenir compte de la faible representation de l'attrition : la **detection d'anomalie**. L'idee consiste a apprendre le profil "habituel" des collaborateurs qui restent, puis a identifier les profils qui s'en ecartent le plus.

```
In [12]: numeric_data = prepare_numeric_anomaly_data(df, drop_columns=["employee_id"])
anomaly_model = MahalanobisAnomalyDetector(regularization=0.1)
anomaly_model.fit(numeric_data.X_train[numeric_data.y_train == 0])
anomaly_val_scores = anomaly_model.score_samples(numeric_data.X_val)
anomaly_thresholds = np.quantile(anomaly_val_scores, np.linspace(0.70, 0.99, 60))
anomaly_best_threshold = find_best_threshold(
    numeric_data.y_val,
    anomaly_val_scores,
```

```

        thresholds=np.unique(anomaly_thresholds),
    )
    anomaly_test_scores = anomaly_model.score_samples(numeric_data.X_test)
    anomaly_metrics = classification_metrics(
        numeric_data.y_test,
        anomaly_test_scores,
        threshold=anomaly_best_threshold["threshold"],
    )

    oversample = random_oversample_minority(prepared.X_train, prepared.y_train, seed)
    oversampled_model = SimpleLogisticRegression(
        learning_rate=0.05,
        epochs=4000,
        reg_strength=0.02,
        class_weight=None,
    )
    oversampled_model.fit(oversample.X_resampled, oversample.y_resampled)
    oversampled_best_threshold = find_best_threshold(
        prepared.y_val,
        oversampled_model.predict_proba(prepared.X_val),
    )
    oversampled_test_scores = oversampled_model.predict_proba(prepared.X_test)
    oversampled_metrics = classification_metrics(
        prepared.y_test,
        oversampled_test_scores,
        threshold=oversampled_best_threshold["threshold"],
    )

    pd.DataFrame(
        [
            (
                "Regression logistique ponderee",
                roc_auc_score_manual(prepared.y_test, test_scores),
                pr_auc_score_manual(prepared.y_test, test_scores),
                test_metrics["recall"],
                test_metrics["f1_score"],
            ),
            (
                "Random oversampling",
                roc_auc_score_manual(prepared.y_test, oversampled_test_scores),
                pr_auc_score_manual(prepared.y_test, oversampled_test_scores),
                oversampled_metrics["recall"],
                oversampled_metrics["f1_score"],
            ),
            (
                "Detection d'anomalie",
                roc_auc_score_manual(numeric_data.y_test, anomaly_test_scores),
                pr_auc_score_manual(numeric_data.y_test, anomaly_test_scores),
                anomaly_metrics["recall"],
                anomaly_metrics["f1_score"],
            ),
        ],
        columns=["Approche", "ROC-AUC", "PR-AUC", "Recall", "F1-score"],
    ).round(4)

```

Out[12]:

	Approche	ROC-AUC	PR-AUC	Recall	F1-score
0	Regression logistique ponderee	0.5951	0.0358	0.0476	0.0323
1	Random oversampling	0.5966	0.0358	0.0476	0.0331
2	Detection d'anomalie	0.5463	0.0284	0.0952	0.0426

Lecture de cette experience

- La detection d'anomalie n'est **pas superieure** au modele supervise en capacite globale de classement.
- En revanche, elle permet de **remonter un peu plus de departs** dans cette experience, au prix d'une precision faible.
- Cette approche peut donc etre utile comme **outil exploratoire complementaire**, mais pas comme solution principale de prediction.

Recommandations

1. Renforcer le suivi des populations a risque dans les segments les plus exposes : France, IT et certaines equipes managers de niveau 1.
2. Utiliser l'engagement, la securite psychologique, l'absenteisme et la charge de travail comme **signaux de prevention** plutot que comme variables de sanction.
3. Cibler davantage les actions de **formation** et de **mobilite interne** pour soutenir la retention.
4. Realiser un audit complementaire sur la **structure de remuneration**, en particulier sur les ecart par genre, poste, pays et niveau.
5. Enrichir le dataset avec des variables plus proches des causes de depart : historique managerial, changements d'equipe, enquetes qualitatives, intentions de mobilite, etc.

Limites

- Donnees desequilibrees avec peu de cas de depart
- Variables explicatives faiblement correlees a l'attrition
- Certaines variables peuvent poser des questions d'equite et d'ethique
- Analyse effectuee sur un dataset unique, sans validation temporelle

La suite logique serait de completer l'approche quantitative par des entretiens RH et une meilleure historisation des evenements de carriere.