

Partie 4 - Restitution Finale

Notebook redigé en vue d'un export PDF. L'objectif est de fournir une restitution complète, argumentée et exploitable pour la prise de décision RH.

```
In [1]: from pathlib import Path
import importlib
import sys
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

PROJECT_ROOT = Path.cwd().resolve()
if not (PROJECT_ROOT / "raw").exists():
    PROJECT_ROOT = PROJECT_ROOT.parent

if str(PROJECT_ROOT) not in sys.path:
    sys.path.append(str(PROJECT_ROOT))

import hr_analysis_utils as utils
importlib.reload(utils)

MahalanobisAnomalyDetector = utils.MahalanobisAnomalyDetector
random_oversample_minority = utils.random_oversample_minority
SimpleLogisticRegression = utils.SimpleLogisticRegression
attrition_by_group = utils.attrition_by_group
attrition_gap_summary = utils.attrition_gap_summary
coefficient_importance = utils.coefficient_importance
correlation_with_attrition = utils.correlation_with_attrition
dataset_overview = utils.dataset_overview
kpi_table = utils.kpi_table
load_data = utils.load_data
add_derived_columns = utils.add_derived_columns
missing_summary = utils.missing_summary
numeric_summary = utils.numeric_summary
plot_bar = utils.plot_bar
plot_box_by_attrition = utils.plot_box_by_attrition
plot_correlation_heatmap = utils.plot_correlation_heatmap
plot_histogram = utils.plot_histogram
plot_top_coefficients = utils.plot_top_coefficients
prepare_model_data = utils.prepare_model_data
prepare_numeric_anomaly_data = utils.prepare_numeric_anomaly_data
pr_auc_score_manual = utils.pr_auc_score_manual
roc_auc_score_manual = utils.roc_auc_score_manual
salary_gap_by_gender = utils.salary_gap_by_gender
average_by_group = utils.average_by_group
top_attrition_segments = utils.top_attrition_segments
find_best_threshold = utils.find_best_threshold
classification_metrics = utils.classification_metrics

DATA_PATH = PROJECT_ROOT / "raw" / "people_analytics_dataset.csv"
raw_df = pd.read_csv(DATA_PATH)
duplicate_employee_ids = int(raw_df["employee_id"].duplicated().sum()) if "employee_id" in raw_df.columns else 0
source_row_count = len(raw_df)
df = add_derived_columns(raw_df.drop_duplicates(subset=["employee_id"]).copy())
```

```
clean_row_count = len(df)
pd.set_option("display.max_columns", 100)
```

Contexte

La DRH souhaite mieux comprendre les dynamiques de depart, d'engagement, d'evolution de carriere, de remuneration et de mobilite interne au sein d'une entreprise internationale d'environ 8 000 collaborateurs.

Le dataset source contient **8 020 lignes** et **28 variables**. Apres suppression de **20 doublons exacts d' `employee_id`**, l'analyse porte sur **8 000 collaborateurs uniques**. L'objectif etait double :

1. transformer les donnees RH en indicateurs de pilotage
2. construire un premier modele de prediction de l'attrition

Faits marquants de l'EDA et de l'analyse RH

1. Une attrition elevee mais heterogene

- Le taux d'attrition global s'etablit a **18,77 %** apres dedoublonnage.
- Les niveaux les plus eleves apparaissent en **Espagne (20,06 %)** et en **France (19,66 %)**.
- Cote departements, **HR (21,53 %)** et **Finance (20,63 %)** sont les plus exposes.

2. L'engagement et la securite psychologique jouent un role de fond

- Les collaborateurs partis ont un **engagement plus faible** que les collaborateurs restes.
- Leur **securite psychologique** est tres nettement plus basse.
- Les populations avec engagement faible affichent un taux d'attrition superieur aux autres groupes.

3. Les conditions de travail donnent des signaux complementaires

- Les collaborateurs partis presentent beaucoup plus d'**absenteisme** et davantage d'**heures supplementaires**.
- Ils ont aussi connu **moins de mobilite interne** et une remuneration legerement plus basse.

4. Carriere, mobilite et remuneration

- Environ **23,9 %** des collaborateurs ont eu une promotion sur 3 ans.
- La **mobilit  interne** concerne un peu plus de **61,8 %** des collaborateurs au moins une fois.

- Le **salaire moyen** est d'environ **62 300** par an, avec une progression nette selon le niveau hierarchique.
- Un ecart brut apparait entre salaire moyen des femmes et des hommes, ce qui justifie une analyse plus fine par poste, pays et niveau.

5. Hypotheses croisees confirmees


- La **mobilite interne** est un signal transversal majeur : sans mobilite, l'attrition depasse 30 % dans toutes les classes d'age ; avec mobilite, elle retombe autour de 9-10 %.
- La **securite psychologique** modere fortement l'effet de la surcharge : une safety haute maintient une attrition faible meme avec des heures supplementaires elevees.
- Le **remote** reduit nettement la visibilite interne, mais cette baisse ne se traduit pas directement par une baisse forte des promotions dans ce dataset.
- Chez les parents en forte surcharge, l'attrition des femmes est environ deux fois plus elevee que celle des hommes, ce qui signale un enjeu RH et d'equite a investiguer.

In [2]: `kpi_table(df)`

Out[2]:

	KPI	Valeur
0	Effectif total	8000.00
1	Taux d'attrition (%)	18.77
2	Score d'engagement moyen	67.79
3	Score de securite psychologique moyen	53.72
4	Taux de promotion sur 3 ans (%)	23.88
5	Taux de mobilite interne (%)	61.91
6	Heures de formation moyennes	34.47
7	Absenteisme moyen (jours)	13.88
8	Heures supp. moyennes	21.06
9	Salaire moyen annuel	62314.12
10	Bonus annuel moyen	5071.92

In [3]: `plot_bar(attrition_by_group(df, "department"), "department", "attrition_rate_pct")`
`plot_bar(attrition_by_group(df, "country"), "country", "attrition_rate_pct", tit`



Resultats du modele predictif

Le modele retenu est une regression logistique interpretable. Il a ete entraine sur les donnees nettoyees, dedoublonnees et encodees, en utilisant **toutes les variables exploitables** du dataset. Seul `employee_id` est exclu, car il s'agit d'un identifiant technique.

```
In [4]: prepared = prepare_model_data(df, drop_columns=["employee_id"])
model = SimpleLogisticRegression(learning_rate=0.05, epochs=4000, reg_strength=0)
model.fit(prepared.X_train, prepared.y_train)
best_threshold = find_best_threshold(prepared.y_val, model.predict_proba(prepared.X_val))
test_scores = model.predict_proba(prepared.X_test)
test_metrics = classification_metrics(prepared.y_test, test_scores, threshold=best_threshold)

pd.DataFrame(
    [
        ("Features utilisees apres encodage", len(prepared.feature_names)),
        ("ROC-AUC", roc_auc_score_manual(prepared.y_test, test_scores)),
    ]
)
```

```

    ("PR-AUC", pr_auc_score_manual(prepared.y_test, test_scores)),
    ("Recall", test_metrics["recall"]),
    ("Precision", test_metrics["precision"]),
    ("F1-score", test_metrics["f1_score"]),
],
columns=["Metrique", "Valeur"],
).round(4)

```

Out[4]:

	Metrique	Valeur
0	Features utilisees apres encodage	93.0000
1	ROC-AUC	0.8102
2	PR-AUC	0.5000
3	Recall	0.6844
4	Precision	0.4000
5	F1-score	0.5049

In [5]: `coefficient_importance(model, prepared.feature_names, top_n=15)`

Out[5]:

	feature	coefficient	abs_coefficient	odds_ratio
11	absenteeism_days	0.7032	0.7032	2.0203
15	psychological_safety_score	-0.4811	0.4811	0.6181
2	contracted_hours_weekly	-0.4755	0.4755	0.6216
9	internal_mobility_count	-0.4183	0.4183	0.6582
7	engagement_score	-0.3397	0.3397	0.7120
10	promotion_last_3y	-0.2860	0.2860	0.7512
3	years_at_company	-0.2199	0.2199	0.8026
16	salary	-0.1431	0.1431	0.8666
86	absence_band_3-5	-0.1418	0.1418	0.8678
12	overtime_hours	0.1383	0.1383	1.1483
92	salary_quartile_Q4	0.1322	0.1322	1.1414
18	stock_options	-0.1218	0.1218	0.8854
89	salary_quartile_Q1	-0.1099	0.1099	0.8959
85	absence_band_0-2	0.1081	0.1081	1.1142
80	engagement_band_Very High	0.0963	0.0963	1.1010

Interpretation

- Les performances du modele sont **solides** sur ce dataset, ce qui rend la priorisation des populations a risque plus credible.

- Les variables les plus contributives vont dans le sens des analyses descriptives : **absenteisme, heures supplementaires, securite psychologique, mobilite interne** et **engagement** participent fortement au signal.
- Le modele utilise desormais l'ensemble des variables exploitables, y compris les variables qualitatives encodees et les variables ajoutees comme `years_at_company` ou `accented_name_flag`.
- Ce resultat suggere que le dataset actuel embarque un signal predictif nettement plus exploitable qu'un simple bruit organisationnel diffus.

Experience complementaire : detection d'anomalie

Une approche alternative a egalement ete testee : la **detection d'anomalie**. L'idée consiste a apprendre le profil "habituel" des collaborateurs qui restent, puis a identifier les profils qui s'en ecartent le plus. Cette experience utilise elle aussi toutes les variables exploitables apres encodage, afin d'etre comparable au modele supervise.

```
In [6]: numeric_data = prepare_numeric_anomaly_data(df, drop_columns=["employee_id"])
anomaly_model = MahalanobisAnomalyDetector(regularization=0.1)
anomaly_model.fit(numeric_data.X_train[numeric_data.y_train == 0])
anomaly_val_scores = anomaly_model.score_samples(numeric_data.X_val)
anomaly_thresholds = np.quantile(anomaly_val_scores, np.linspace(0.70, 0.99, 60))
anomaly_best_threshold = find_best_threshold(
    numeric_data.y_val,
    anomaly_val_scores,
    thresholds=np.unique(anomaly_thresholds),
)
anomaly_test_scores = anomaly_model.score_samples(numeric_data.X_test)
anomaly_metrics = classification_metrics(
    numeric_data.y_test,
    anomaly_test_scores,
    threshold=anomaly_best_threshold["threshold"],
)

oversample = random_oversample_minority(prepared.X_train, prepared.y_train, seed
oversampled_model = SimpleLogisticRegression(
    learning_rate=0.05,
    epochs=4000,
    reg_strength=0.02,
    class_weight=None,
)
oversampled_model.fit(oversample.X_resampled, oversample.y_resampled)
oversampled_best_threshold = find_best_threshold(
    prepared.y_val,
    oversampled_model.predict_proba(prepared.X_val),
)
oversampled_test_scores = oversampled_model.predict_proba(prepared.X_test)
oversampled_metrics = classification_metrics(
    prepared.y_test,
    oversampled_test_scores,
    threshold=oversampled_best_threshold["threshold"],
)

pd.DataFrame(
```

```
[
    (
        "Regression logistique ponderee",
        roc_auc_score_manual(prepared.y_test, test_scores),
        pr_auc_score_manual(prepared.y_test, test_scores),
        test_metrics["precision"],
        test_metrics["recall"],
        test_metrics["f1_score"],
    ),
    (
        "Random oversampling",
        roc_auc_score_manual(prepared.y_test, oversampled_test_scores),
        pr_auc_score_manual(prepared.y_test, oversampled_test_scores),
        oversampled_metrics["precision"],
        oversampled_metrics["recall"],
        oversampled_metrics["f1_score"],
    ),
    (
        "Detection d'anomalie",
        roc_auc_score_manual(numeric_data.y_test, anomaly_test_scores),
        pr_auc_score_manual(numeric_data.y_test, anomaly_test_scores),
        anomaly_metrics["precision"],
        anomaly_metrics["recall"],
        anomaly_metrics["f1_score"],
    ),
],
columns=["Approche", "ROC-AUC", "PR-AUC", "Precision", "Recall", "F1-score"]
).round(4)
```

Out[6]:

	Approche	ROC-AUC	PR-AUC	Precision	Recall	F1-score
0	Regression logistique ponderee	0.8102	0.5000	0.4000	0.6844	0.5049
1	Random oversampling	0.8082	0.4972	0.4045	0.6611	0.5019
2	Detection d'anomalie	0.5018	0.1939	0.2162	0.3455	0.2660

Lecture de cette experience

- La regression logistique ponderee reste l'approche la plus pertinente : elle combine performance solide et interpretation metier.
- L'oversampling n'ameliore pas vraiment le modele : il modifie legerement le compromis precision/recall, mais n'apporte pas de gain net.
- La detection d'anomalie devient nettement moins convaincante lorsque toutes les variables sont prises en compte : son **ROC-AUC** est proche de 0,50, ce qui indique une capacite de classement tres limitee.

Recommandations

1. Renforcer le suivi des populations a risque dans les segments les plus exposes : **Espagne, France**, ainsi que les departements **HR, Finance** et **Sales**.
2. Utiliser la **securite psychologique**, l'**absenteisme**, la **charge de travail** et l'**engagement** comme signaux de prevention a traiter en priorite.

3. Cibler davantage les actions de **mobilité interne**, de **promotion** et d'intégration des collaborateurs les moins anciens pour soutenir la rétention.
4. Investiguer spécifiquement les populations **parents + forte surcharge**, ou l'écart d'attrition femmes/hommes est très marqué.
5. Réaliser un audit complémentaire sur la **structure de rémunération**, en particulier sur les écarts par genre, poste, pays et niveau.
6. Encadrer strictement l'usage des variables sensibles ou discutables (`gender` , `accented_name_flag`) et enrichir le dataset avec des variables plus directement causales : historique managérial, changements d'équipe, enquêtes qualitatives, intentions de mobilité, etc.

Limites

- Dataset unique, sans validation temporelle ni test sur une autre cohorte
- Certaines variables peuvent être très proches du phénomène à prédire, ce qui peut gonfler artificiellement la performance
- Certaines variables peuvent poser des questions d'équité et d'éthique
- L'utilisation de toutes les variables améliore l'exhaustivité du modèle, mais impose une vigilance accrue sur les variables sensibles et les variables potentiellement proxy
- Résultats à confirmer avant toute utilisation opérationnelle large

La suite logique serait de compléter l'approche quantitative par des entretiens RH et une meilleure historisation des événements de carrière.