

Partie 5 - Synthese Executive

Format court, redige pour un comite de direction. Ce notebook peut etre exporte en PDF
1 a 2 pages.

```
In [1]: from pathlib import Path
import importlib
import sys
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

PROJECT_ROOT = Path.cwd().resolve()
if not (PROJECT_ROOT / "raw").exists():
    PROJECT_ROOT = PROJECT_ROOT.parent

if str(PROJECT_ROOT) not in sys.path:
    sys.path.append(str(PROJECT_ROOT))

import hr_analysis_utils as utils
importlib.reload(utils)

MahalanobisAnomalyDetector = utils.MahalanobisAnomalyDetector
random_oversample_minority = utils.random_oversample_minority
SimpleLogisticRegression = utils.SimpleLogisticRegression
attrition_by_group = utils.attrition_by_group
attrition_gap_summary = utils.attrition_gap_summary
coefficient_importance = utils.coefficient_importance
correlation_with_attrition = utils.correlation_with_attrition
dataset_overview = utils.dataset_overview
kpi_table = utils.kpi_table
load_data = utils.load_data
add_derived_columns = utils.add_derived_columns
missing_summary = utils.missing_summary
numeric_summary = utils.numeric_summary
plot_bar = utils.plot_bar
plot_box_by_attrition = utils.plot_box_by_attrition
plot_correlation_heatmap = utils.plot_correlation_heatmap
plot_histogram = utils.plot_histogram
plot_top_coefficients = utils.plot_top_coefficients
prepare_model_data = utils.prepare_model_data
prepare_numeric_anomaly_data = utils.prepare_numeric_anomaly_data
pr_auc_score_manual = utils.pr_auc_score_manual
roc_auc_score_manual = utils.roc_auc_score_manual
salary_gap_by_gender = utils.salary_gap_by_gender
average_by_group = utils.average_by_group
top_attrition_segments = utils.top_attrition_segments
find_best_threshold = utils.find_best_threshold
classification_metrics = utils.classification_metrics

DATA_PATH = PROJECT_ROOT / "raw" / "people_analytics_dataset.csv"
raw_df = pd.read_csv(DATA_PATH)
duplicate_employee_ids = int(raw_df["employee_id"].duplicated().sum()) if "employee_id" in raw_df.columns else 0
source_row_count = len(raw_df)
df = add_derived_columns(raw_df.drop_duplicates(subset=["employee_id"]).copy())
```

```
clean_row_count = len(df)
pd.set_option("display.max_columns", 100)
```

1. Ce qu'il faut retenir

- L'entreprise presente un **turnover eleve (18,77 %)**, avec des poches de risque bien identifiees.
- Les principaux signaux lies au depart sont une **securite psychologique plus faible**, un **absenteisme plus eleve**, davantage d'**heures supplementaires**, moins de **mobilite interne** et un **engagement plus bas**.
- Les zones a surveiller en priorite sont **l'Espagne, la France**, ainsi que les departements **HR, Finance** et **Sales**.
- Les analyses croisees confirment trois leviers prioritaires : **mobilite interne, securite psychologique en contexte de surcharge**, et vigilance sur les **parents en forte charge de travail**.

In [2]: `kpi_table(df).head(8)`

Out[2]:

	KPI	Valeur
0	Effectif total	8000.00
1	Taux d'attrition (%)	18.77
2	Score d'engagement moyen	67.79
3	Score de securite psychologique moyen	53.72
4	Taux de promotion sur 3 ans (%)	23.88
5	Taux de mobilite interne (%)	61.91
6	Heures de formation moyennes	34.47
7	Absenteisme moyen (jours)	13.88

2. Facteurs cles influencant turnover et engagement

Turnover

- plus eleve dans certains segments organisationnels
- associe a des conditions d'emploi moins favorables dans ce dataset
- plus marque chez les collaborateurs les moins ancrés dans l'organisation : moindre anciennete, moins de promotions et moins de mobilite interne
- desormais previsible avec un niveau de performance utile pour la priorisation RH

Engagement

- plus faible dans les populations qui quittent l'entreprise

- article avec des leviers de management, de charge de travail, de reconnaissance et de securite psychologique

3. Resultat du modele predictif

Le modele detecte un **signal exploitable** :

- il est utile pour orienter la vigilance RH et prioriser les actions de retention
- il ne doit pas etre utilise seul pour prendre des decisions individuelles
- il utilise toutes les variables exploitables du dataset, hors identifiant technique `employee_id`
- il confirme l'importance de la securite psychologique, de l'absenteisme, de l'engagement, de la mobilite interne, de l'anciennete et de la charge de travail dans la lecture du risque
- l'oversampling n'apporte pas de gain net ; la **detection d'anomalie** reste nettement moins robuste que le modele supervise

```
In [3]: prepared = prepare_model_data(df, drop_columns=["employee_id"])
model = SimpleLogisticRegression(learning_rate=0.05, epochs=4000, reg_strength=0)
model.fit(prepared.X_train, prepared.y_train)
best_threshold = find_best_threshold(prepared.y_val, model.predict_proba(prepared.X_val))
scores = model.predict_proba(prepared.X_test)

pd.DataFrame(
    {
        "Metrique": ["Features utilisees", "ROC-AUC", "PR-AUC", "Recall", "Precision"],
        "Valeur": [
            len(prepared.feature_names),
            roc_auc_score_manual(prepared.y_test, scores),
            pr_auc_score_manual(prepared.y_test, scores),
            classification_metrics(prepared.y_test, scores, threshold=best_threshold),
            classification_metrics(prepared.y_test, scores, threshold=best_threshold)
        ]
    }
).round(4)
```

```
Out[3]:
```

	Metrique	Valeur
0	Features utilisees	93.0000
1	ROC-AUC	0.8102
2	PR-AUC	0.5000
3	Recall	0.6844
4	Precision	0.4000

4. Recommandations operationnelles

1. Prioriser les plans d'action RH sur les segments les plus exposes au turnover.
2. Integrer l'engagement, la securite psychologique, l'absenteisme et la charge de travail dans un dispositif de veille RH trimestriel.

3. Renforcer les parcours de mobilité, de promotion et d'intégration des profils les moins anciens comme leviers de rétention.
4. Traiter les situations de forte surcharge, en particulier chez les parents, avec une lecture spécifique des écarts femmes/hommes.
5. Lancer une analyse plus fine de l'équité salariale et du rôle des variables sensibles.
6. Améliorer la qualité des données, encadrer l'usage des variables sensibles et confirmer les résultats sur de nouvelles cohortes avant toute utilisation plus large.